

## SPLEX TME 3

### Mélange de Gaussiens et l'algorithme EM

*Implementer l'algorithme EM et tester le sur les données "obeses\_temoins" pour clusteriser les patients en deux classes. Comparez vous resultats avec ceux obtenus avec un package R, par exemple, le package R "mclust".*

#### Mélange de Gaussiens

Si le événements sont issus d'une composition de  $N$  phénomènes, la densité  $p(X)$  prendra la forme d'une composition de lois normales. On peut l'approximer par une somme pondérée de densité normales, "mélange de Gaussiens"

$$p(x) = \sum_{m=1}^M \alpha_m \mathcal{N}(x; \mu_m, \Sigma_m), \quad (1)$$

ou

$$\mathcal{N}(x, \mu, \Sigma) = \frac{1}{(2\pi)^{D/2} \det(\Sigma)^{\frac{1}{2}}} \exp \left( -1/2(x - \mu)^T \Sigma^{-1}(x - \mu) \right). \quad (2)$$

. Dans le mélange de Gaussiens il faut estimer trois paramètres

$$(\alpha, \mu, \Sigma). \quad (3)$$

Si toutes les  $\mu$  et  $\Sigma$  etait fixe, on pourrait calculer les  $\alpha_m$  directement. Mais ils sont libres et il faut donc les esimer par un processus iterative. Un tel processus est composé de deux étapes.

#### Algorithme EM

Soit une ensemble "training set" de  $N$  observation  $X_{n=1}^N$ ,  $z^n \in \{0, 1\}^m$  est l'indicateur de classe. La log-vraisemblance est

$$L(\alpha, \mu, \Sigma) = \sum_n \sum_m z_m^n \left( \ln \alpha_m - \frac{1}{2} \ln |\Sigma_m| - \frac{1}{2} \text{tr}(\Sigma_m^{-1}(x^n - \mu_m)(x^n - \mu_m)^T) \right) \quad (4)$$

On fait une premier estimation des paramètres  $(\alpha, \mu, \Sigma)$  et puis on altern "Expectation" et "Maximisation" pendant plusieurs iterations  $t$ , tant que l'algorithme n'a pas convergé.

- “Expectation step”: Faire une estimation des valeurs manquantes (“hidden”)

$$z_m^n = p(z_m^n = 1 | x^n, \alpha^{\text{old}}, \mu^{\text{old}}, \Sigma^{\text{old}}) = \frac{\alpha_m^t \mathcal{N}(x_n; \mu_m^t, \Sigma_m^t)}{\sum_{j=1}^M \alpha_j^t \mathcal{N}(x_n; \mu_j^t, \Sigma_j^t)}. \quad (5)$$

- “Maximisation step”:

$$\alpha_m = \frac{1}{N} \sum_n z_m^n, \quad (6)$$

$$\mu_m = \frac{\sum_n z_m^n x^n}{\sum_n z_m^n}, \quad (7)$$

$$\Sigma_m = \frac{\sum_n z_m^n (x^n - \mu_m)(x^n - \mu_m)^T}{\sum_n z_m^n}. \quad (8)$$